

OmniAgent

设计报告

设计目标、核心亮点、中级任务与验收边界

版本日期：2026-10-01

匿名技术材料 · 依据官方赛题与当前实际运行证据

阅读边界：本地开发验收与真实模型验收分别呈现。指定模型 gpt-6-luna 尚未通过鉴权；本文不把规则回退称为模型成功，不将开发题成绩换算为官方成绩。

核心亮点预览（一）：架构与证据

系统面向“数据库里的数值”和“文档里的口径”需要共同回答的问题。结构化问数、独立知识库与跨源执行器共享来源契约；前端直接展示实际 SQL、引用位置、计算参数和失败原因。




图 1 系统架构与共享证据契约（与当前源码对应）

处理链路：用户问题→结构化会话→SQL/文档/跨源路由→有界工具执行→证据与单位校验→答案和可回看来源。PDF、DOCX、XLSX、TXT、MD、PNG 入库后保留页、行、单元格或 OCR 区域定位。

当前验收	结果	口径
问数开发验收	12/12	规则规划、合成开发题
多格式问答开发验收	11/11	混合检索、原文摘录与引用核对
跨源工具链开发验收	5/5	明确工具计划，非未知模型规划
公开 Chinook 开发题	12/12	公开库，人工题，非 Spider 基准
真实 gpt-6-luna	authentication_failed	models 及 responses 探测 401，未有模型成绩

核心亮点预览（二）：中级任务覆盖

要求	能力	当前证据
M01	要素识别、别名与改写	NFKC、值词边界、5/5 文本扰动
M02	低示例跨领域	Chinook 11 表、0 few-shot, 开发题 12/12
M03	主动澄清	指标、时间、值、JOIN 歧义与回填
M04	数十表 Schema Linking	11/40/80 表干扰, 9/9 开发案例
M05	JOIN、聚合、嵌套	关系图、复合键、粒度与防扇出
M06	文档公式与数据结合	AST、来源绑定、单位与预测年份守卫
M07	非标准目录	层级标题、行号、跳跃告警
M08	复杂度自适应	PageSignal 及 900 字/80 重叠复杂切片
M09	低质 OCR 恢复	10 种合成扰动, 原图 8/10→增强 10/10

重点贡献是把公式、数值、单位、日期版本及工具依赖绑定到真实来源。缺失依据、政策重叠、零分母、币种冲突和已知预测年份不符均停止最终结论。

覆盖实现不代表所有官方未知测试均已通过。模型通用规划、独立保留题、公开 OCR 基准及跨源五轮真实模型评测仍需进一步验证。

需求与任务边界

依据 specification/official-track8.pdf（14 页正式赛题），基础任务包括单表问数、单文档问答、可解释展示及交互 Demo；中级任务涵盖九类难点；决赛需要多源协同、多跳、澄清与连续五轮。

本项目建立在独立目录中，迁移已有 NL2SQL 与未提交优化作为受保护基线。原生产项目仅作为只读借鉴源，不作为运行服务、私有知识库或密钥依赖。

对象	当前支持	边界
数据库	SQLite 演示库与公开 Chinook	其他数据库方言未作运行验收
文档	15 份实际文件、6 种格式	合成样本，非真实客户资料
模型	指定 Responses 兼容接口	仅 gpt-6-luna，鉴权尚未通过
交互	问数/知识库/验收工作台	本地开发服务，不声称完成生产审计

系统对无证据、歧义、错误计划和不可执行的查询显式返回状态；不会为提高表面完成率而使用猜测答案。

问数设计：意图与可执行口径

Schema 自动解析表、字段、主外键与关系；值索引把“华东”等实际值绑定到正确列。Unicode 归一化、繁简与别名处理降低输入差异；显式字段与最长字段匹配防止短词抢占长指标。

计划由指标、时间、过滤、分组、聚合、排序与 JOIN 结构组成。模型不直接执行裸 SQL；同一安全门检查字段合法性、覆盖率、JOIN 粒度和只读性。模糊意图进入澄清接口，用户选择后回填。

跨域扩展首先增加 Schema 和业务指标口径，而非为每一道题追加字符串模板。Chinook 与干扰表实验证明有限场景可运行，尚不能推导任意业务数据库准确率。

五轮会话示例：2025 华东销售额→改华南→改 2024→换订单数→换华北。结构化条件替换避免把前轮已撤销条件误叠加。

多模态与检索设计

文本 PDF 优先保留原生文本与页块，扫描 PDF 和图片调用 RapidOCR ONNX CPU。DOCX 段落、XLSX 行列、TXT/MD 标题路径保留结构。低质量图片执行有界增强并保留原始结果。

BGE-small-zh-v1.5 固定公开 revision 与 SHA，以 CLS 归一化向量提供真正 Dense 检索。BM25 提供精确词匹配，RRF 融合排名。明确编号先作为范围约束，避免 CASE0005 与 CASE00050 混淆。

知识库原文件内容寻址，保存 SHA 与定位片段。答案可以回看原文件；定位、原文和数字核验失败时拒绝把候选片段包装为确定结论。

开发阈值 0.35/0.6 未经过独立校准；OCR 置信度选优是工程启发式，不是语义正确保证。

跨源设计：每一步都有来源

执行计划每步包含 id、tool 和 args，最多 16 步；ref/path 定义实际依赖。运行前拒绝循环、缺失依赖、重复 ID 和未知工具。SQL 或文档结果只有通过契约后才能作为后步参数。

场景	依赖链	核验
预测	文档公式→全年 SQL 基准→Excel 增长率→计算	基准年、目标年、参数适用年
回款	SQL 金额→Excel 费率→计算	金额单位与百分数尺度
门槛判定	SQL 指标→文档阈值→比较	阈值原文、单位及时间
政策问答	多版本文档→日期选择→事实	生效时间、重叠与缺失
客户口径	SQL 实体→文档说明→汇总	实体范围及引用

已核对例子：2025 华东销售额 29584，按来源增长率 12%得到 2026 预测 33134.08。错年份停止，不显示该中间数值为最终答案。该结果仅用于合成样本验收。

评估设计与当前结果

评测	结果	解释
问数开发验收	12/12	规则规划、合成开发题
多格式问答开发验收	11/11	混合检索、原文摘录与引用核对
跨源工具链开发验收	5/5	明确工具计划，非未知模型规划
公开 Chinook 开发题	12/12	公开库，人工题，非 Spider 基准
真实 gpt-6-luna	authentication_failed	models 及 responses 探测 401，未有模型成绩

本地 391 项回归覆盖接口、安全、语义与拒绝路径；一个 Starlette 弃用警告不影响当前通过，但需在依赖升级时处理。

结果匹配优先比较执行后的行与列，不把 SQL 字符串相等当作准确率。问答同时检查预期事实与引用；OCR 对比原图与同一扰动样本，避免无对照的增强宣传。

计划下一阶段冻结独立保留题、引入未知 Schema、遮蔽开发答案后实测；模型验证必须检查 provider/model 及回退状态，不允许混入规则结果。

效率、成本与工程取舍

PDF 页数	切片数	全局语义热 P50/ms	全局语义热 P95/ms
10	50	19.093	19.575
100	500	109.542	115.637
500	2500	541.472	616.101

以上是实际文字 PDF 入库后的混合检索与摘录答案，不含 OCR 与外部生成。500 页首次全局回答约 16.1 秒，说明冷启动编码成本必须单列。明确编号快速查询不代表一般语义查询延迟。

数据库已实测 1 千、1 万、10 万行；10 万行热简单查询约 11.6ms、嵌套约 77.2ms、同比约 291.7ms。1/4/8 线程规则查询约 13.63/28.44/33.93QPS，不当作模型吞吐。

优化优先顺序：缓存 Schema/向量、预热模型、索引和限定候选，再控制工具调用与上下文长度。API 计费 and 端到端 token 成本因 401 尚未实测，不给虚构费用。

交付与部署

完整资产包包含源码、Schema、15 份实际样本、公开 BGE 权重、Chinook 与许可。runtime 凭据、日志、缓存及基线 ZIP 不进入交付包。依赖锁定文件记录当前实测环境，跨平台安装仍需对应平台 wheel。

启动：python -m pip install -r delivery/requirements-tested.txt; python tools/run_server.py --port 8030。打开首页、knowledge.html 和 capabilities.html。API 模式先 probe 通过，再加--with-model；未通过时保留显式规则/摘录模式。

验包工具核对逐文件 SHA，在全新目录解包并重建数据库、样本入库、随机端口启动，验证 health、前端、SQL、Dense、RAG 与 OCR。当前检查点通过，最终材料加入后需再次验包。

组委会 Word/PPT 模板尚未提供，本材料采用匿名自定义排版，不声称已套用官方模板。最终提交前应按届时模板迁移，并补录真实模型及保留集结果。