

OmniAgent

技术实现说明书

模块契约、实现机制、评测与复现

版本日期：2026-10-01

匿名技术材料 · 依据官方赛题与当前实际运行证据

阅读边界：本地开发验收与真实模型验收分别呈现。指定模型 gpt-6-luna 尚未通过鉴权；本文不把规则回退称为模型成功，不将开发题成绩换算为官方成绩。

系统架构与运行模式

模块	源码	契约
结构化问数	backend/nl2sql/	Schema 与值链接→计划→安全 SQL→只读执行
文档知识库	knowledge_store.py / chunk_cleaning.py	原文件 SHA→解析/OCR→有定位的切片
混合检索	dense_retrieval.py / cross_source.py	BM25 与本地 BGE→RRF→编号/证据门
跨源推理	dependency_agent.py / formula_binding.py	有界依赖计划→来源数值→公式与单位核验
可信生成	grounded_generation.py / responses_client.py	结构化 claims→原文引用与数字核对
持续会话	session.py / omni_agent.py	结构化槽位→五轮上下文→主题清空

FastAPI 提供统一同源接口，开发服务绑定 127.0.0.1；前端不读取密钥。用户通过 omni/query 进入结构化 SQL、文档或融合计划。规则模式、模型模式和回退状态在返回结果中区分。

Schema Linking 与要素识别

backend/nl2sql 读取 SQLite 元数据，构建表字段与主外键图；值词与字段别名共同产生候选。列名采用 NFKC 归一化，保留原始 SQL 标识符并统一引用，避免中文/英文或全角输入导致不可执行。

显式字段优先，长字段优先于短字段；主题日期与业务时间槽位分别处理。对于“金额”“数量”等宽泛指标先展示候选而非擅选。值边界避免词中片段命中错误实体。

11/40/80 表的 9 个开发测试核对选择的表、字段、结果，Schema 干扰并非真实企业 80 表基准。角色关联与同名列的泛化仍需要额外盲测。

查询计划、JOIN 与 SQL 验证

自然语言解析得到可校验结构化计划：目标指标、聚合、分组、时间窗口、过滤与关系路径。模型仅提交受限结构，编译器处理参数化值，禁止模型生成 SQL 绕过编译。

关系图检查完整复合键和连接方向。聚合前确认事实表粒度，拒绝会让数值复制的 JOIN；多种同等关系时请求澄清。去重计数与合计保持不同语义。

SQL AST 和只读连接拒绝 DDL/DML、多语句、未批准字段及危险结构；限制行数和执行时间。空结果作为有效结果状态，区别于数据库错误或缺少证据。

用金标 SQL 执行结果核对，而不是词面模板吻合。Chinook12 道题覆盖已知场景，复杂任意 SQL 生成能力尚未取得独立评测成绩。

澄清与持久会话

nl2sql/clarify 接收明确候选选择并回填计划。澄清针对会改变结果的字段、单位、时间或连接歧义；安全错误不得通过用户随意点击绕过。

session.py 以 SQLite 保存结构化槽位与最近五轮状态，设置 TTL 与容量；重启可以恢复。新主题清空不适用条件，短跟进输入替换条件，不把全部历史自然语言简单拼接。

网页已经完成五轮地区/年份/指标替换，结果 29584→22992→4998→1→1。该序列是合成规则模式演示，不代表多源模型五轮未知题已经全部通过。

文件解析、结构与切片

knowledge_store.py 保存文档元数据、内容地址与切片。支持 PDF、DOCX、XLSX、TXT、MD、PNG；先检查格式、大小与解析并发，再进入格式专用解析器。

text_structure.py 识别 Markdown、数字、中文与括号标题，保存行号与父级路径。标题跳跃给出告警，不把规则推断层级标作人工金标。

PageSignal 记录页上文本、块、图及质量等实际信号，决定解析与切片策略。复杂路径采用 900 字长度和 80 字重叠；正文、表格与 OCR 区域都有对应 locator。

原文件下载接口在回看前核验 SHA。知识库和原始样本都属于本项目，不依赖 D 盘生产知识库或远程服务。

OCR 与低质量恢复

ocr.py 使用 RapidOCR ONNX CPU 识别中文与英文，返回文字、bbox、置信度及变换历史。扫描 PDF 按页栅格化，图片保留来源。

质量判断同时参考图像信号与识别结果。低质量图片即使原始平均 confidence 偏高也执行有界增强；最多三次尝试，将原图也保留为候选，选择置信度较高的结果。

十种成对合成扰动原图 8/10，pipeline 10/10。固定预期“2 小时/24 小时”等事实核验，不只比较置信度。该实验非 OHR-Bench，样本量不足以给统计泛化保证。

风险：高置信错字、表格错行及编号误读仍可能出现。对于影响计算的 OCR 数值保留原始区域与低置信提示，未知金额不可无来源写入工具参数。

Dense、BM25 与融合检索

dense_retrieval.py 加载 BGE-small-zh-v1.5，
revision=7999e1d3359715c523056ef9478215996d62a620，使用 safetensors、不允许
remote code 或 pickle 加载。CLS 向量归一化后执行 cosine 计算。

BM25 与 Dense 结果按 RRF 融合并保留各路 rank/cosine/score。缓存 key 包含模型 revision、标题和内容；更新文档或模型不能误复用旧向量。

明确实体编号作为范围约束：CASE0005 必须精确出现，CASE00050 不满足；不存在的编号返回无证据。这是精确实体守卫，不宣称通用实体链接已解决。

开发阈值属于待校准参数。候选片段不足时摘录回退或拒答，不能把高相似度当作事实蕴含。

有依据生成与指定 API

responses_client.py 提供 Responses 兼容结构化输出、超时和脱敏 audit。

grounded_generation.py 要求 claims 与 literal quote，核验引用存在及数字一致。逐字引用有效并不证明完整语义蕴含。

tools/model_runtime.py 仅读取 runtime/model_config.json；模型只允许 gpt-6-luna，域名只允许 https://spacetimeai.cc（实际请求/v1）。不读 Codex 旧凭据，不切换其他模型。

指定 API 实际探测：/v1/models、/models 和 /v1/responses 均 401。models 失败不能直接判断模型不存在；401 只说明请求未通过鉴权。当前没有可用的真实生成成绩。

鉴权恢复后依次运行 probe_model.py 与 evaluate_model.py --full，检查返回 model、provider、usage 及回退标签。禁止用成功的规则 SQL 替代真实模型能力证明。

有界 DAG 与跨源工具

dependency_agent.py 支持 sql、search、document_formula、cell、fact、calculate、policy_select、compare。每一步 ID 唯一；ref/path 形成实际依赖图，上游失败时下游不执行。

计划最大 16 步；先验证依赖、循环、工具白名单与参数契约。运行 trace 记录输入证据、结果与状态，前端展示实际调用链，不展示虚构的模型内部思考。

工具输出分离数值、单位、来源与验证状态。数据型参数只能引用 SQL 单元格、XLSX 或已定位文档，不接受 literal 代替可信来源。

融合五流程已通过明确计划验收；未知自然语言转复杂计划的鲁棒性需 gpt-6-luna 实测。

公式、单位、年份与政策版本

formula_binding.py 从实际文档提取公式并解析 AST，白名单算术拒绝代码执行与非法表达式。零分母和非有限数值立即失败，参数名称与引用来源显式绑定。

unit_algebra.py 管理数值尺度、百分数、金额及币种，禁止冲突币种默默计算。年份守卫核验文档基准年/目标年、SQL 全年范围以及 Excel 参数适用年；无法推断时标 not_inferred。

policy_evidence.py 按明确生效日期选版本，重叠或缺失阻止答案。已验证退货期限 5 日→7 日的边界，ASCII 逗号不再让政策值带入整个日期句。

未知单位、隐含生效条件和复杂公式语义仍可能需要主动澄清，不由启发式强行补齐。

解释链路与前端契约

首页展示问数、SQL 与结果；knowledge.html 展示文档、统一多轮及跨源场景；capabilities.html 按赛题要求列出证据与未完成项。

可解释信息包括 SQL 及参数、来源 SHA、页/行/单元格/OCR 定位、公式、引用值、单位与日期、工具依赖和失败原因。提供的解释是执行记录，不承诺揭示模型隐含推理。

融合结果 incomplete 时不把已完成步骤的中间数值当作最终答案；模型生成失败保持显式摘录回退。API 探测状态显示时间戳，保存的历史记录不等于实时可用性。

服务限制查询长度、行数、文件大小与并发；生产 Bearer/CORS 配置有边界。当前本地部署尚不等同多租户生产权限审计。

功能评估：输入、金标与判定

测试	当前结果	判定口径
问数开发验收	12/12	规则规划、合成开发题
多格式问答开发验收	11/11	混合检索、原文摘录与引用核对
跨源工具链开发验收	5/5	明确工具计划，非未知模型规划
公开 Chinook 开发题	12/12	公开库，人工题，非 Spider 基准
真实 gpt-6-luna	authentication_failed	models 及 responses 探测 401，未有模型成绩

本地 391 项回归主要检验实现契约、异常与安全路径；不能把单元测试数量作为准确率分母。开发问数比较结果，问答核对事实与原文，跨源核对数值及来源依赖。

评测输入、结果、运行脚本和范围标记一起入包。history 中的旧模型结果只属于历史资料，不纳入 gpt-6-luna 评测。

未见题验收需要冻结输入/金标且避免修复后仍称其为未见；报告失败原因为 Schema、检索、生成、计算或授权，不能只输出平均成功率。

复杂度与规模效率

页数	切片	语义热 P50/ms	语义热 P95/ms
10	50	19.093	19.575
100	500	109.542	115.637
500	2500	541.472	616.101

设表数 T 、字段数 C 、关系边 E 、切片数 N 、向量维度 d 、检索 k 、计划步数 S 。Schema 遍历约 $O(T+C+E)$ ，关系路径搜索约 $O(T+E)$ ；SQL 成本由扫描、索引与 JOIN 基数决定。

当前精确 Dense 矩阵扫描约 $O(Nd)$ ，Top- k 约 $O(N \log k)$ ；BM25 倒排依赖命中 posting 数。RRF 融合约 $O(k \log k)$ ，DAG 校验 $O(S+\text{依赖边数})$ 。外部模型延迟随输入输出 token 变化，不能套用本地线性公式。

1k/10k/100k 行与 10/100/500 页已经分规模实测。冷编码、热缓存、编号缩小候选与全局语义必须分别报告；OCR 和真实模型端到端效率尚未验收。

复现、许可与未完成项

delivery/requirements-tested.txt 记录直接依赖实测版本；ENVIRONMENT.json 记录完整包版本、Python 与平台。模型权重与 Chinook 各有 ASSET_MANIFEST 和 LICENSE，样本为自建合成 CC0。

先安装依赖，按 README 启动；完整资产包无需复制原项目。verify_checkpoint.py 对新目录解包、逐文件哈希、重建与独立随机端口作验收，源码包则需要公开资产下载。

未完成：gpt-6-luna 有效鉴权；独立未知题；公开复杂 OCR 样本；通用跨源五轮；真实模型耗时/token 成本；官方模板迁移及真实评审反馈。

本文按官方赛题内容制作，不以未提供的官方模板名义提交；仅有当前证据的条目可表述为“已验收”。