

OmniAgent

决赛深化技术文档 准备稿

多源推理、可靠性、实验设计与提交门槛

版本日期：2026-10-01

匿名技术材料 · 依据官方赛题与当前实际运行证据

阅读边界：本地开发验收与真实模型验收分别呈现。指定模型 gpt-6-luna 尚未通过鉴权；本文不把规则回退称为模型成功，不将开发题成绩换算为官方成绩。

决赛深化范围与证据等级

本材料是当前实现的决赛技术深化准备稿，不假称已经收到初赛评审反馈。最终版应补充真实评委意见、逐项响应与新增实验。

等级	定义	当前情况
实现	源码存在且通过契约回归	九类中级能力与融合执行器
开发验收	已知输入与金标实测	SQL、QA、融合、Chinook 与扰动
独立效果	保留题或公开标准协议	尚未提供完整成绩
真实模型	指定接口成功且无回退	gpt-6-luna 鉴权 401

评委可以在验收工作台逐项回看证据，所有指标附范围；不把覆盖数量、开发题通过率和奖项预期混在一起。

多源任务组合与现场路线

五种已通过的跨源流程包含文档公式+SQL 客单价、PDF+SQL+Excel 预测、Excel 地区→SQL、SQL 排名→文档冠军经验和文档检索+Excel 阈值。政策版本比较是额外边界案例。trace 核对前步结果对后步的实际影响。

主路线：自然语言问数→文档解释→三源预测→故意错年份→政策新旧日期→澄清选择→五轮条件变化。失败案例和正常案例同屏展示。

当前工具计划可运行；通用模型计划仍需指定接口恢复后验证。现场无 API 时明确进入规则/摘录演示，不使用预录模型答案冒充在线结果。

可计算证据与时间一致性

三源预测必须具有文档公式、SQL 基准数值与参数表适用年。每项带 locator 和 SHA，计算器保留 AST 与引用。

$29584 \times (1 + 12\%) = 33134.08$ 为合成验收例子；若目标年/基准年/SQL 全年窗口不匹配，返回 incomplete。未知年份标 not_inferred，不默认为验证通过。

政策版本按问题日期选择已生效条款；重叠条款不能靠最新文档名猜测。退货期限 5 日和 7 日已作边界比较，依赖日期证据而不是文件排序。

可靠性深化 拒绝也是正确行为

故障	期望行为	证据
未知实体编号	无证据，不用近似编号	编号边界回归
参数缺失/零分母	不输出最终数值	DAG 与 AST 测试
JOIN 粒度不符	澄清或拒绝	复合键/防扇出测试
币种冲突	停止计算	单位契约
API 鉴权失败	明确回退或停止	401 脱敏探测

同一组十项实际临时副本故障首次 4/10，修复后 10/10；原文件篡改或缺失停止旧切片与公式链，SQL 缺库/锁定停止后步，硬 kill 子服务重启后五轮和 pending 澄清继续，会话锁 503 后解锁保留原历史。仅为开发审计，不代表掉电容灾。

正确拒绝率和错误拒绝率应在后续独立题集分别报告。仅测正常路径会掩盖系统在数据冲突时生成自信错误的风险。

检索深化 语义召回与实体边界

Dense 可以弥补纯词匹配，但近似编号和不同政策版本必须额外控制。实体约束与时间约束先限定可比证据，RRF 再在合法范围中融合。

第一次 500 页评测暴露了错误合同编号，已通过精确编号守卫修复。这项修复说明需要错误案例反馈，不意味着 Dense 所有语义检索问题已经解决。

编号和无编号全局语义评测分开。500 页全局语义热 P50=523.822ms、P95=618.806ms，首次全局回答 5.390s。来源选中后核验；首次全局、首载模型与热缓存单列，不以编号快速路径替代一般语义延迟。新旧环境/缓存不同，不宣称固定倍数加速。

低质量文档的证据保留

OCR 返回识别原文、区域、confidence 与变换历史，允许回看原图。三次尝试的选择规则保留原始候选，避免增强覆盖正确识别。

合成成对抗动 8/10→10/10 仅为开发证据。下一阶段需要真实拍照、倾斜、污损、表格错行与不同扫描仪，按文档分组拆分，防止同一页的不同扰动跨越训练与测试。

评价应包含字符错误率、关键数字准确率、引用定位与下游问答结果。平均置信度只用于候选排序，不作为最终准确率。

未知题与消融实验方案

冻结保留题：问数按未见 Schema、表达和 SQL 结构划分；文档按未见原文件划分；融合按未见依赖组合划分。金标在实验前固定，并标明制定者与来源。

消融	比较对象	指标
移除 Dense	BM25 与混合检索	Recall@k、来源准确率
移除编号守卫	近似编号冲突题	误引用率
移除年份/单位守卫	冲突融合题	危险计算率
关闭 OCR 增强	同文档成对抗动	关键事实正确率
关闭结构会话	五轮条件变化	每轮执行准确率

这些是待执行的实验方案，不预填增益或显著性。无需宣称优于公开 SOTA；先证明对目标场景的可复现效益。

部署 成本与生产前置

当前包含本地 95,827,648 字节 BGE 权重与 Chinook，在线生成依赖指定 API。CPU 检索可独立运行；OCR 与模型首载占用单独统计。

生产前需要数据权限、租户隔离、审计、配置轮换、限流与故障恢复。现有只读 SQL 和开发本机绑定解决执行边界，不等同数据库所有表都可以向所有用户开放。

真实评测准备 44 题，SQL 内部也接真实规划器；每题汇总路由、生成、SQL 及重试，usage 缺失保持未知。唯一预检 401，题目未执行，不估费用。压缩包不是无依赖离线安装镜像。

材料依据与最终提交门槛

全部量化结论对应 docs 中的原始 JSON，delivery/SOURCE_MANIFEST.json 保存本轮材料来源 SHA。报告和 PPT 不包含用户名、单位、密钥或真实客户信息。

最终提交门槛：有效 gpt-6-luna 实测；五类跨源与五轮模型验收；独立保留集；依赖锁；材料页数与匿名检查；完整资产新目录启动；逐文件哈希；官方模板检查。

当前已经实现的能力可以演示，但这些未完成门槛必须如实列明。正式定稿更新资料与实验数据后重新生成材料和压缩包，不能沿用过期报告。